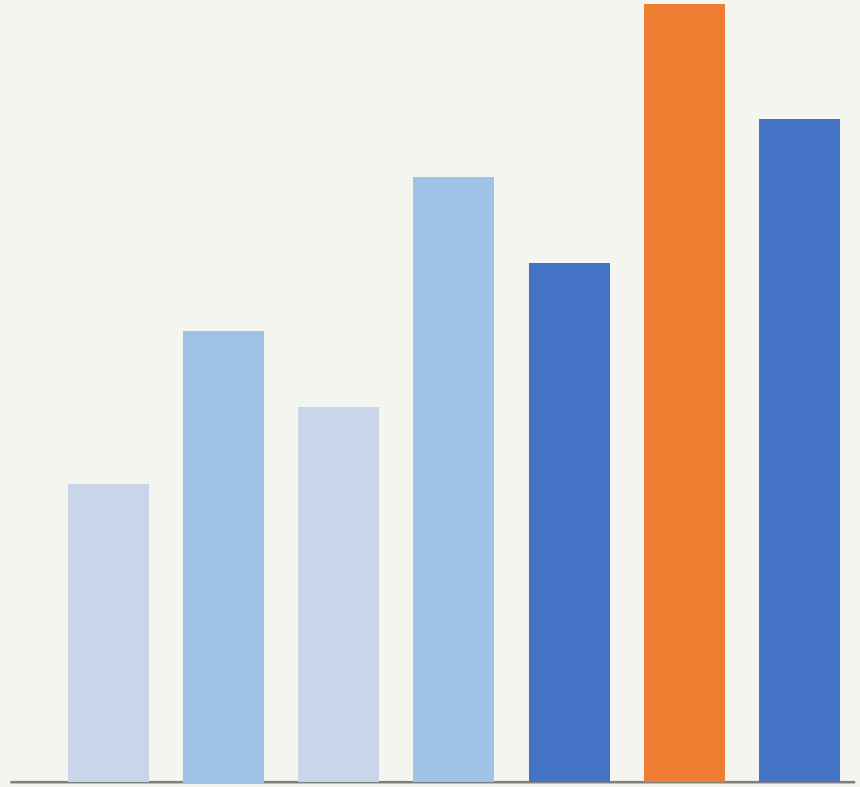
DATA SCIENCE ACADEMY

Prevedere la depressione negli studenti universitari



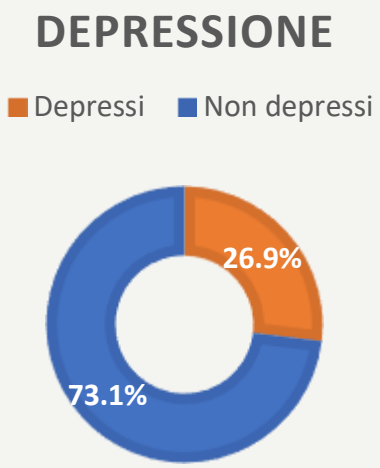
Alessandro Bonfiglio · Iustin Adrian Dinu · Alessandro Rausa

2026

Il campione

Variabili numeriche

Variabile	Mediana	Q1–Q3	Min–Max
Età (anni)	23	21–24	17–28
Semestre	5	3–7	0–13
CGPA (scala 0–4)	3,49	3,15–3,70	2,25–4,00
Costo extra-studio	9.500	6.100–15.439	0–32.000



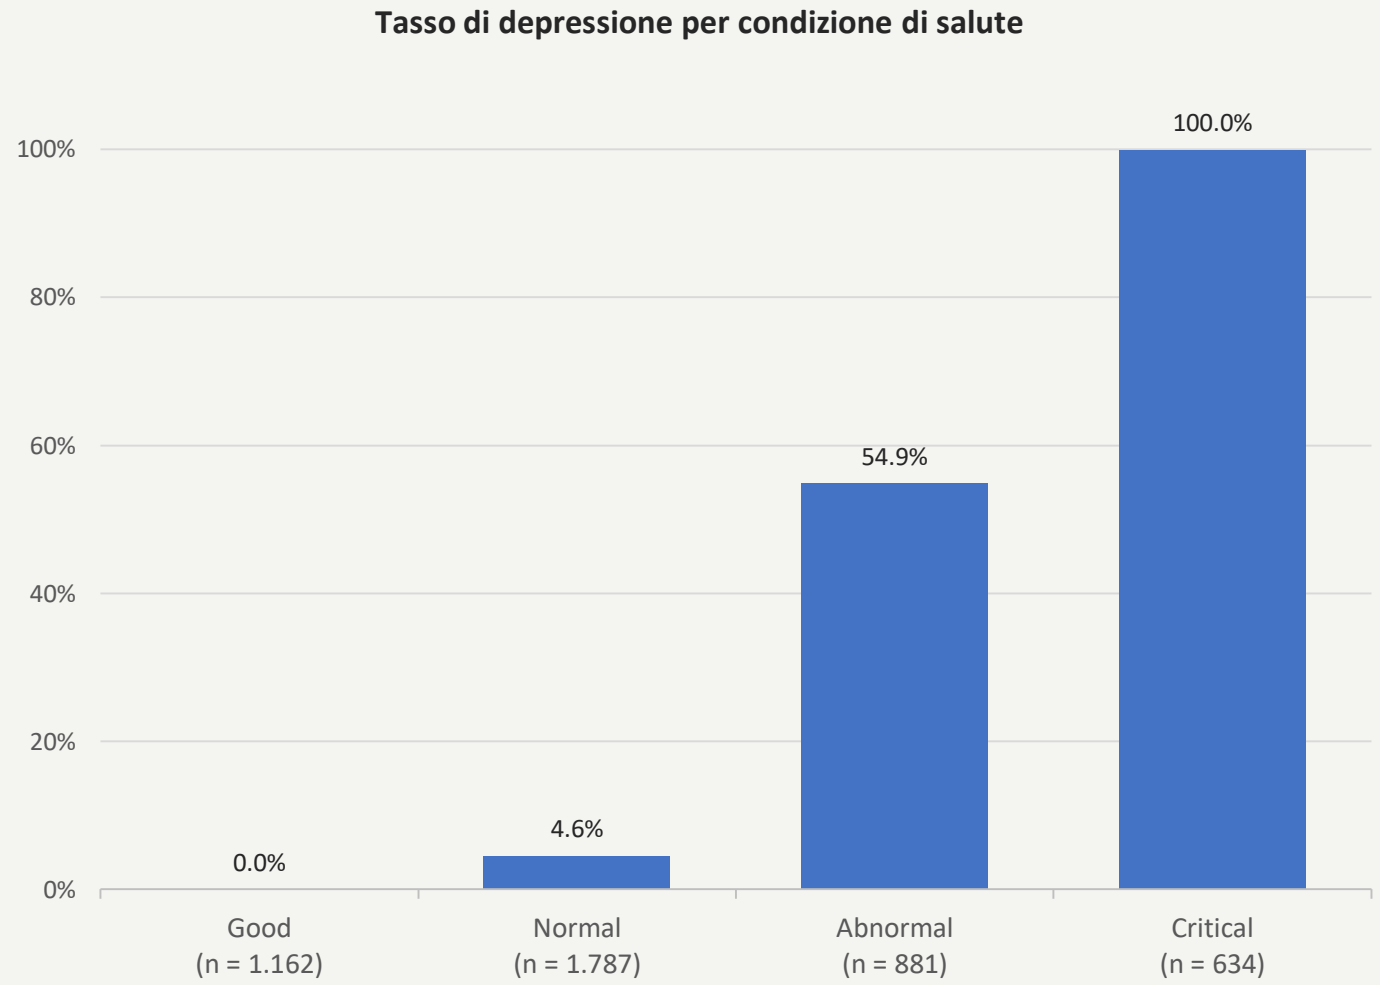
- 1.201 studenti su 4.464 si dichiarano depressi.
- La variabile indicante la condizione di salute è esclusa dall'analisi.

Variabili categoriche (% del campione)

Variabile	Distribuzione
Genere	Femmine 55% · Maschi 45%
Classe sociale	Media 59% · Medio-bassa 26% · Alta 15%
Stato relazionale	Single 63% · In coppia 33% · Complicata 5%
Stato civile	Non sposato 81% · Sposato 16% · Separato 3%
Abitazione	Da solo 55% · In famiglia 45%
Cerchia di amici	Sì 72% · No 28%
Divisione	Dhaka 34% · Altre 7 città 66%

Fonte: Student Depression Dataset, studenti universitari del Bangladesh. Link: https://www.kaggle.com/datasets/mkhoirulmustaqim/student-depression-detection-dataset

La condizione di salute coincide con il target e resta fuori

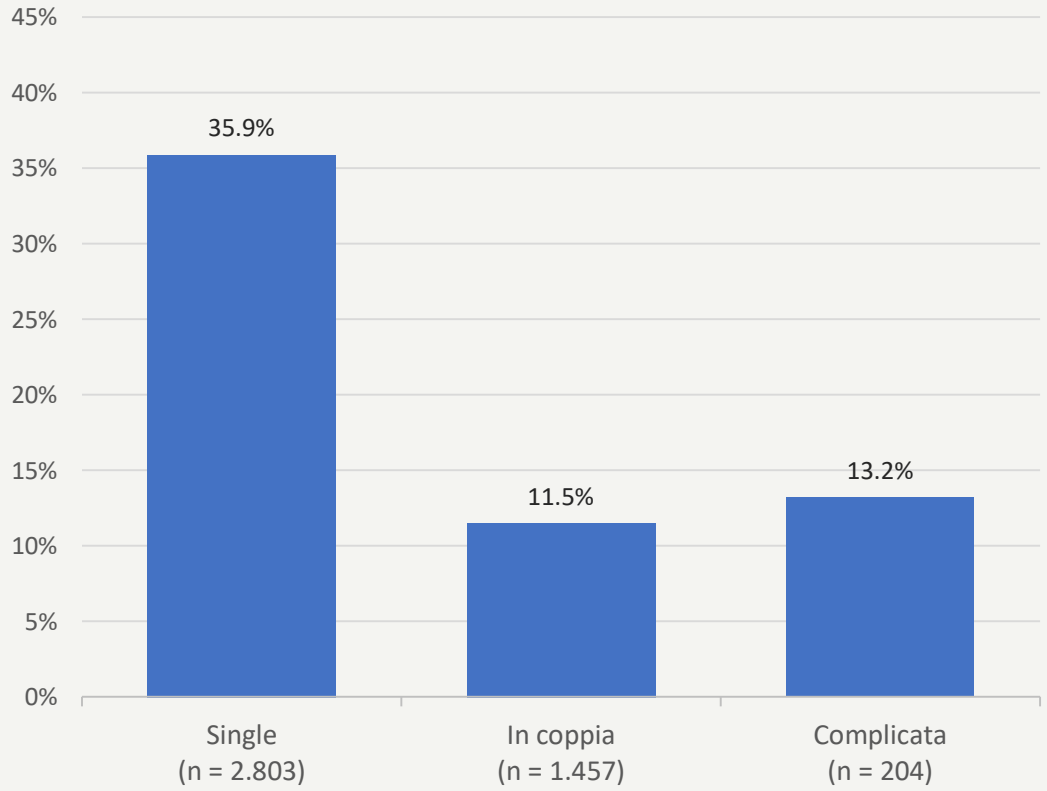


- Nessuno studente appartenente alla categoria ‘Good' è depresso, tutti i 'Critical' lo sono (V di Cramér 0.81, contro 0.26 della seconda variabile).
- La condizione di salute probabilmente include già lo stato mentale, tenerla nei modelli renderebbe la previsione banale.
- Nel controllo dei dati sono emerse poche incoerenze:
  - 42 studenti al semestre 0
  - 2 studenti con costo extra-studio pari a 0

Test chi-quadro tra condizione di salute e depressione: $p < 0{,}001$.

I single si dichiarano depressi tre volte più spesso

Tasso di depressione per stato relazionale



V di Cramér 0,26, l'associazione più forte tra le variabili analizzate. Tasso medio del campione 26,9%.

Tasso di depressione, con e senza cerchia di amici

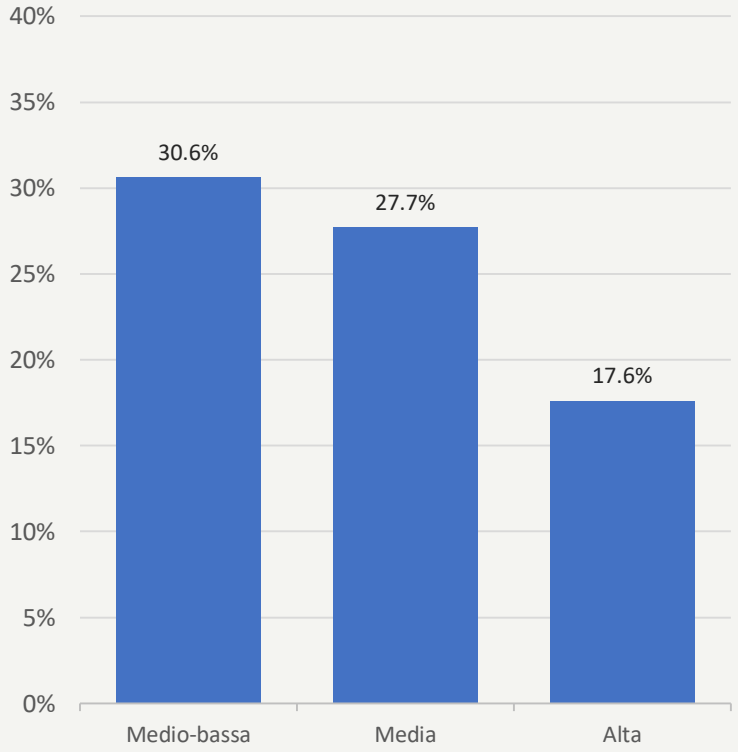
	Senza amici	Con amici
Single	44.1% (n = 774)	32.8% (n = 2.029)
In coppia	17.7% (n = 389)	9.2% (n = 1.068)
Complicata	20.9% (n = 86)	7.6% (n = 118)

Avere una cerchia di amici abbassa il tasso in tutti e tre i gruppi; tra i single si passa dal 44% al 33%.

Differenza tra con e senza amici significativa in tutti i gruppi (chi-quadro con correzione di Bonferroni: $p < 0{,}001$ per single e in coppia, $p = 0{,}03$ per complicata).

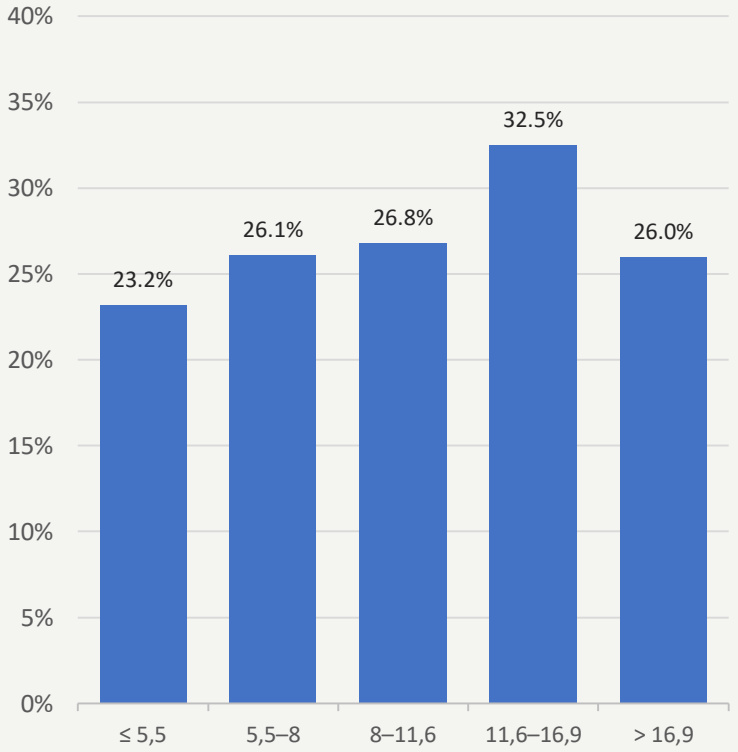
Il tasso scende con la classe sociale e con il voto medio

Classe sociale



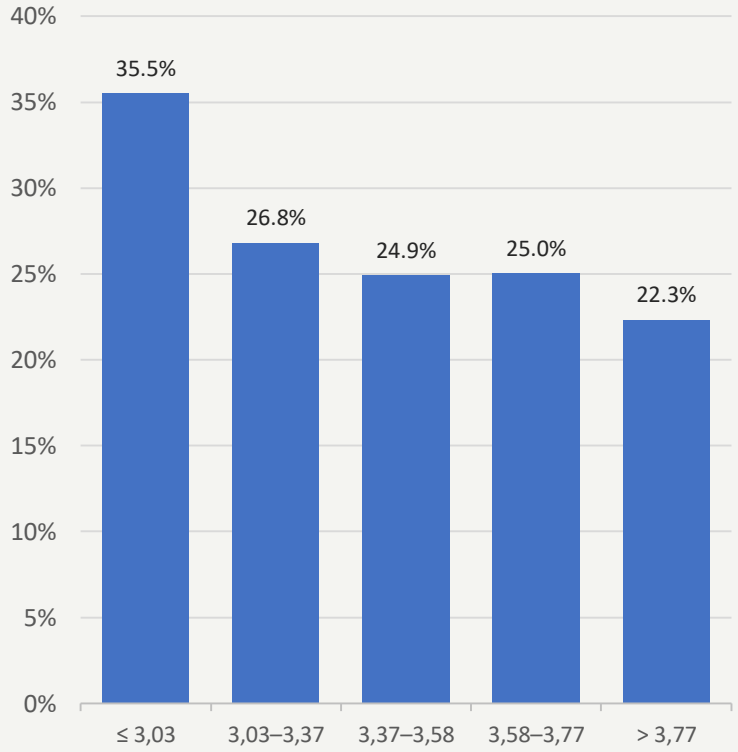
Dalla classe medio-bassa a quella alta il tasso quasi si dimezza (V di Cramér 0,09).

Costo extra-studio (quintili)



Il picco nel quarto quintile dipende dalla classe sociale: dentro ogni classe, costi più alti vanno con tassi più alti.

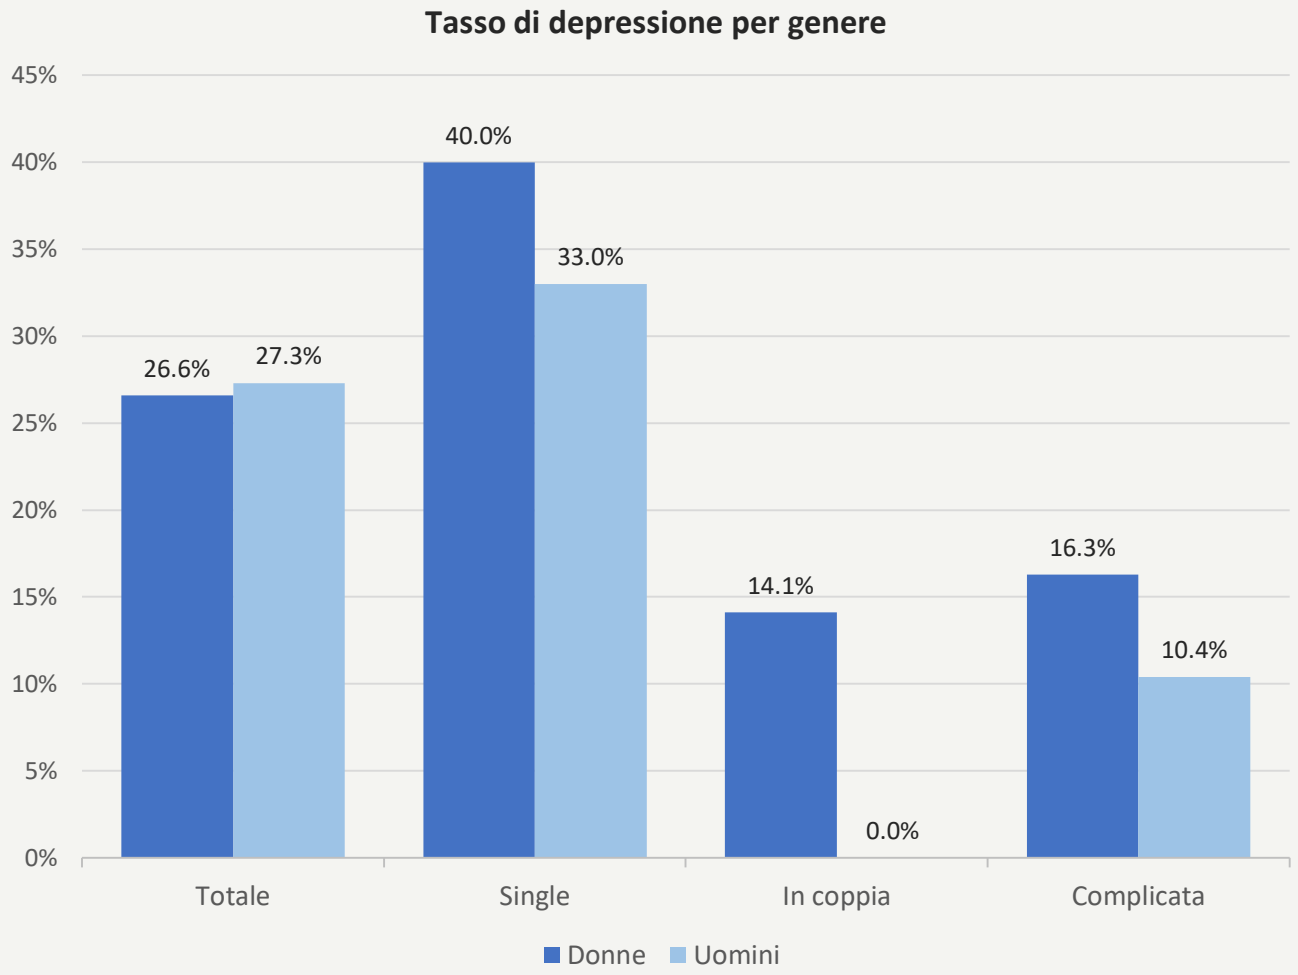
Media voti (quintili)

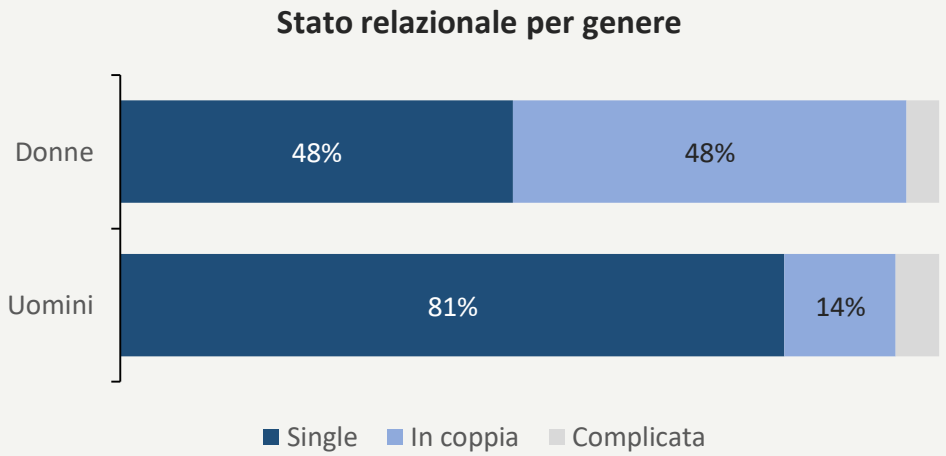


Il quinto con il voto più basso ha il tasso più alto. Mediana 3,42 nei depressi, 3,50 negli altri.

Quintili in migliaia per il costo e in punti (scala 0–4) per il CGPA. Classe, costo e CGPA: chi-quadro $p < 0{,}001$.

A parità di stato relazionale, le donne sono più spesso depresse



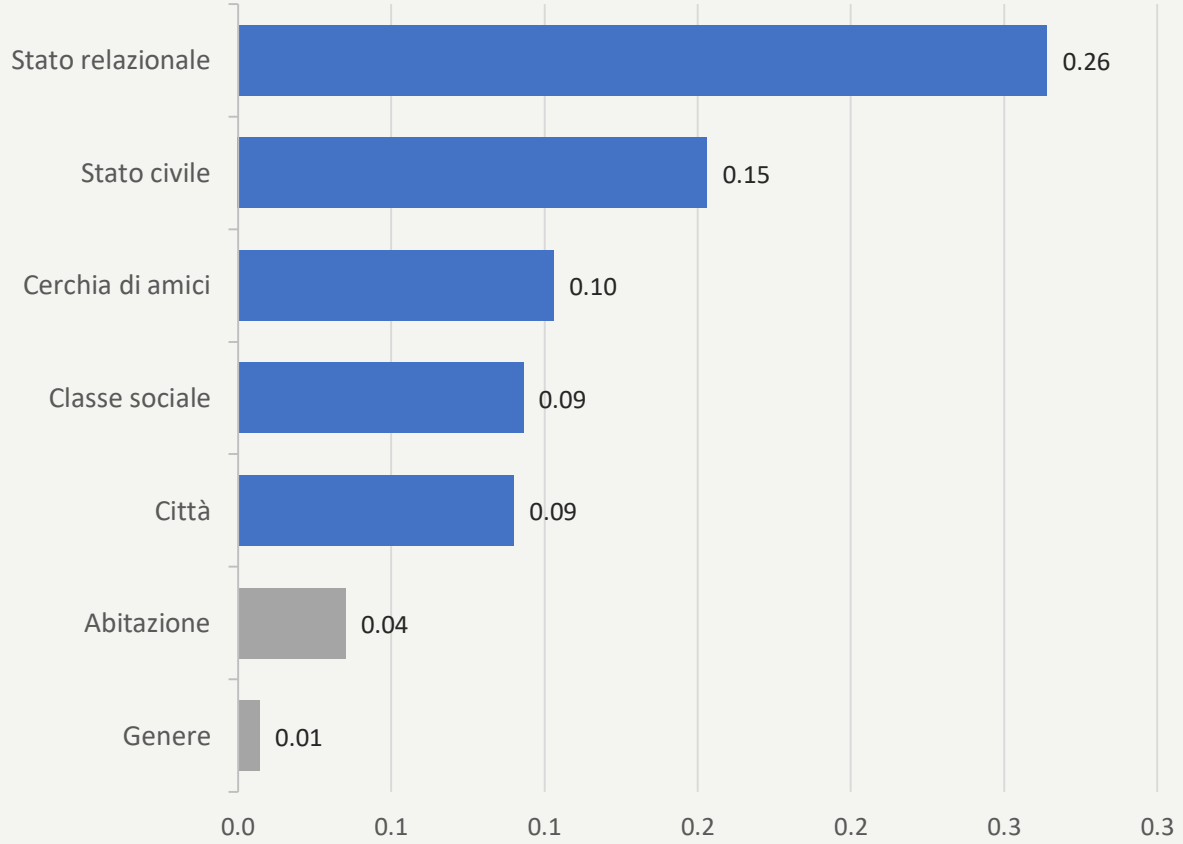


- Nel totale i tassi quasi coincidono perché l'81% degli uomini è single, il gruppo più a rischio.
- Il dato aggregato nasconde quindi l'effetto del genere.
- Nella logistica, a parità di altre variabili, essere uomo riduce l'odds di depressione rispetto al genere femminile.

Differenza tra generi significativa per single e in coppia (chi-quadro, $p < 0{,}001$), non per complicata ($p = 0{,}30$, $n = 204$). Nessuno dei 273 uomini in coppia si dichiara depresso.

Lo stato relazionale è il fattore più legato alla depressione

Variabili categoriche, V di Cramér



In grigio: non significative dopo Bonferroni (genere p = 1,00, abitazione p = 0,15).

Variabili numeriche, mediane per gruppo

Variabile	Non depressi	Depressi	p corr.	U
Media voti	3,50	3,42	< 0,001	0,56
Costo extra-studio	9.300	10.000	0,084	0,48
Età	23	23	0,037	0,53
Semestre	5	5	0,98	0,51

- Le associazioni sono tutte deboli: solo tre variabili superano 0,10, la soglia convenzionale di effetto debole.
- Tra le numeriche solo il CGPA mostra una differenza chiara, con effetto piccolo (U = 0,56); nessuna variabile da sola basta a distinguere chi è depresso.
- Nei modelli sono quindi usate tutte le variabili ad eccezione della menzionata condizione di salute.

Chi-quadro con p corretti con Bonferroni su 8 test (salute inclusa, V = 0,81). Numeriche: Mann-Whitney, Bonferroni su 4 test; U = probabilità che un non depresso abbia il valore più alto.

Il benchmark: la logistica riconosce solo un depresso su cinque

Odds ratio (9 variabili scelte con forward selection)

Variabile	Odds ratio	IC 95%
Single	4,94	3,99 – 6,10
Non sposato	1,83	1,41 – 2,37
Costo extra-studio	1,56	1,39 – 1,75
Media voti	0,77	0,71 – 0,83
Vive a Dhaka	0,68	0,57 – 0,82
Ha una cerchia di amici	0,67	0,56 – 0,80
Classe media	0,66	0,54 – 0,81
Uomo	0,57	0,48 – 0,68
Classe alta	0,22	0,15 – 0,34

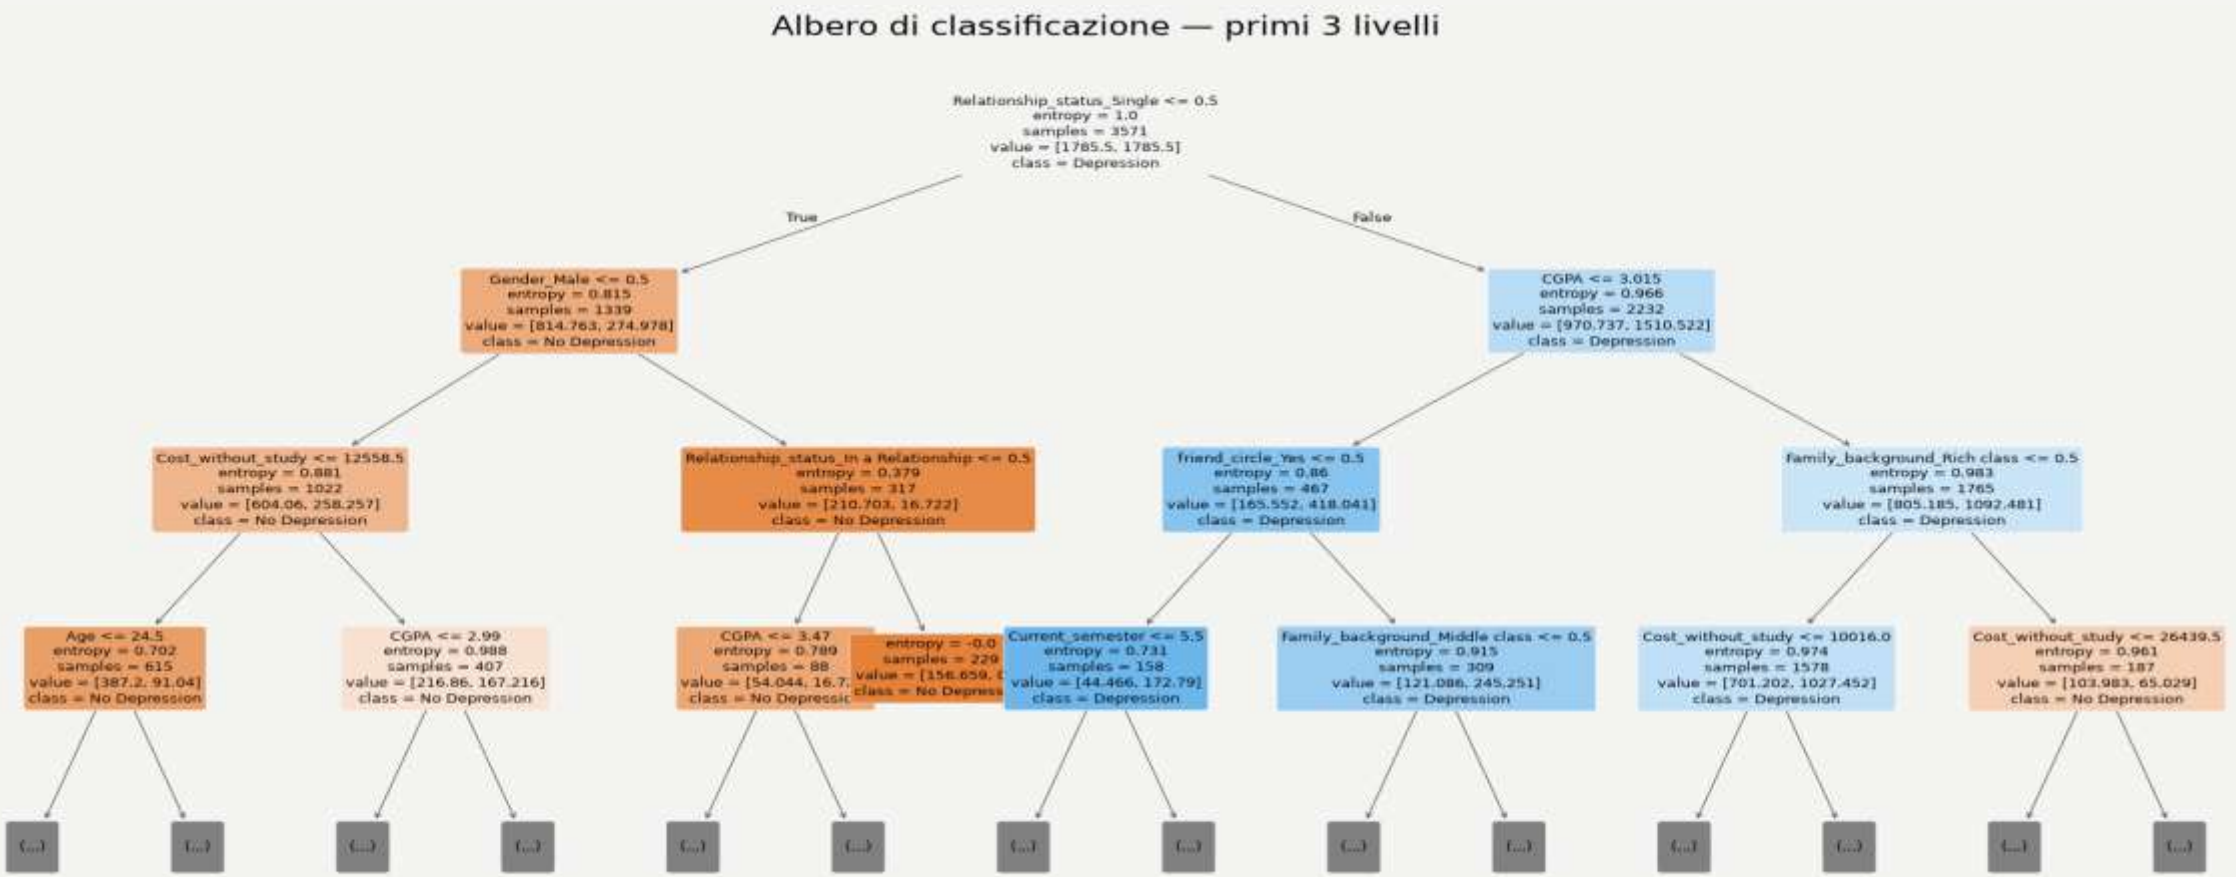
Sul test, soglia 0.5 (893 studenti)

	Previsto depresso	Previsto non depresso
Depresso (240)	47	193
Non depresso (653)	44	609

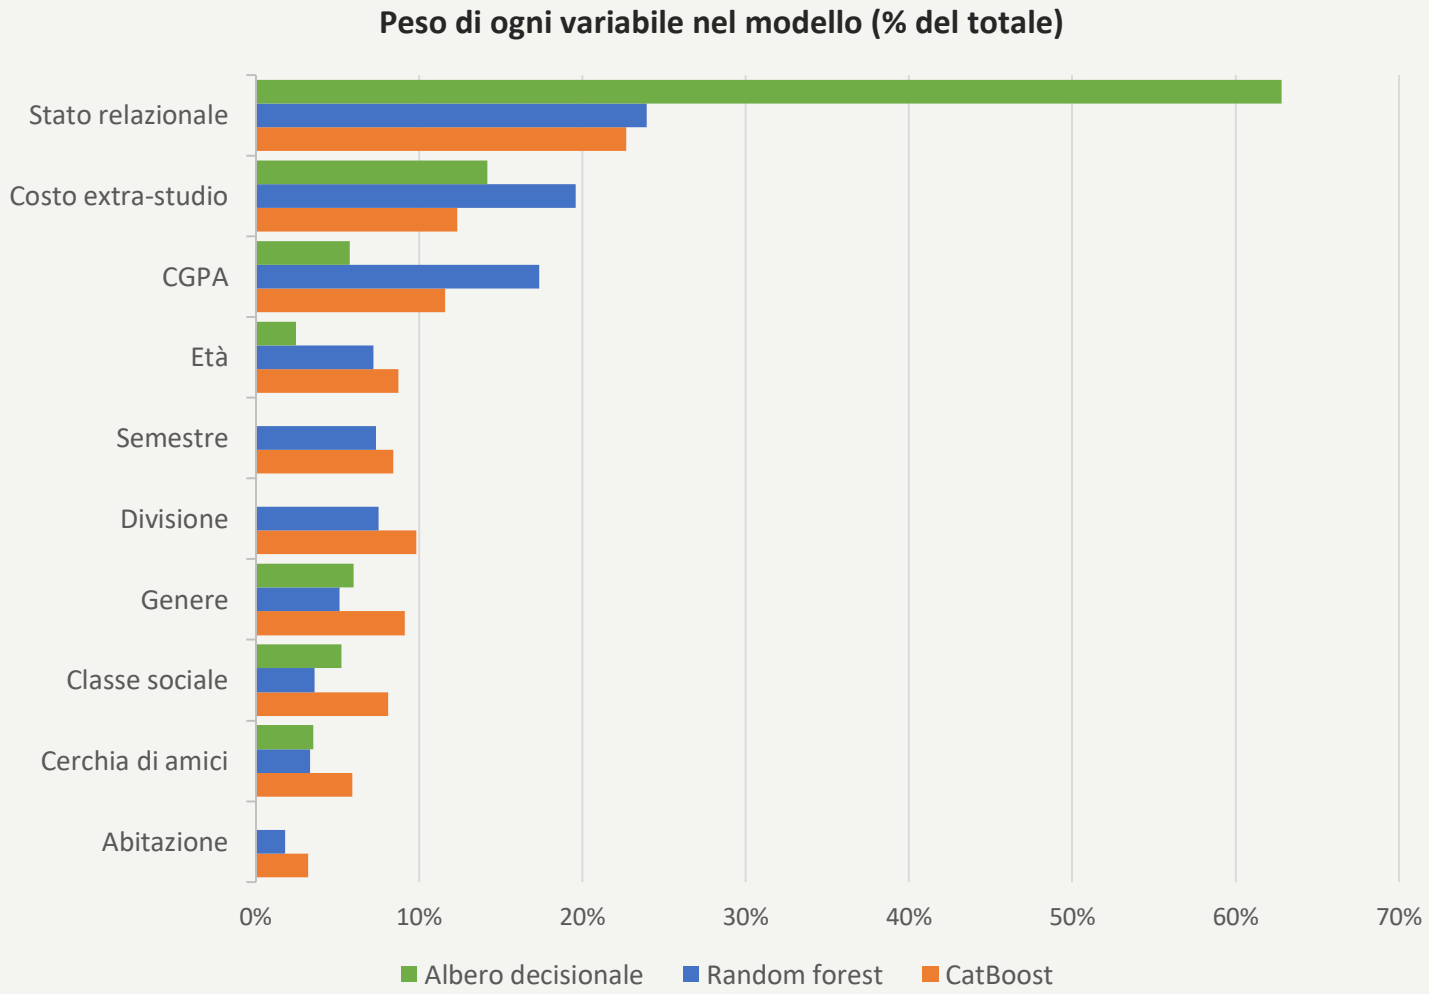
- Riconosce 47 depressi su 240 (recall 20%).
- Accuracy 73,5%, appena sopra il 73,1% che si otterrebbe rispondendo sempre «non depresso».
- Gli odds ratio confermano la descrittiva: essere single quintuplica l'odds, la classe alta lo riduce di quasi l'80%.

Stime sul train (3.571 studenti), tutte con $p < 0{,}001$, pseudo R^2 0,12. Riferimenti: in coppia o complicata, sposato o separato, classe medio-bassa, donna, senza amici, fuori Dhaka.

L'albero decisionale



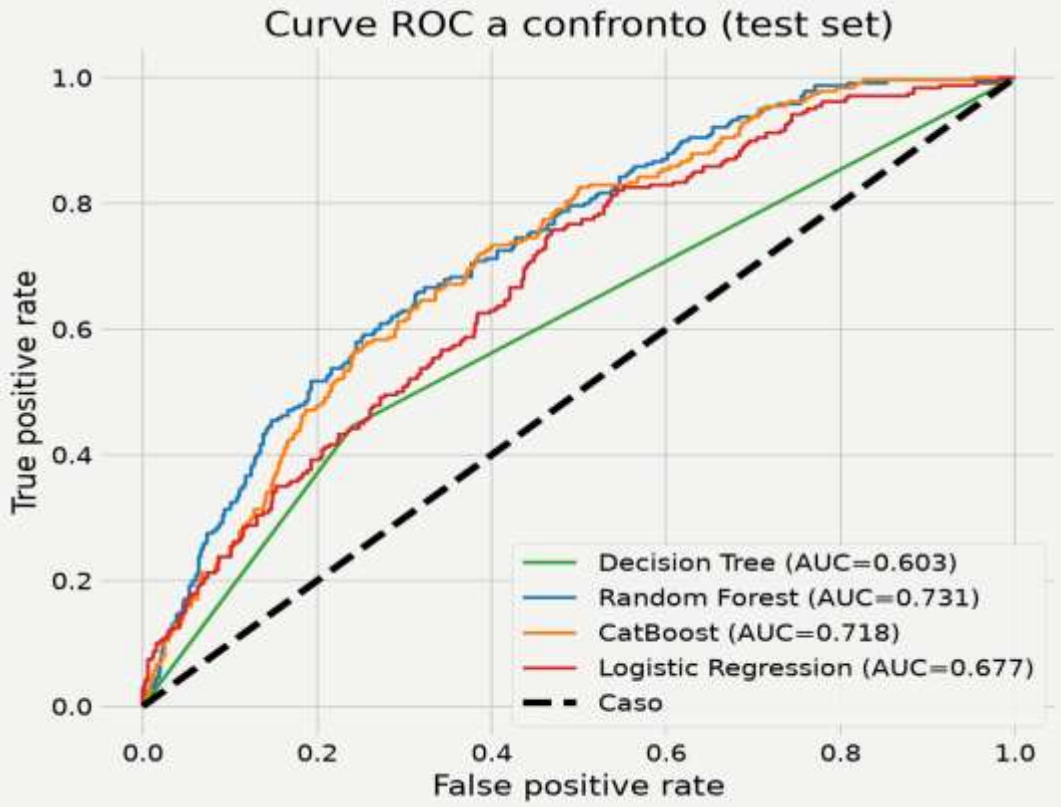
Gli ensemble usano anche costo, voto ed età

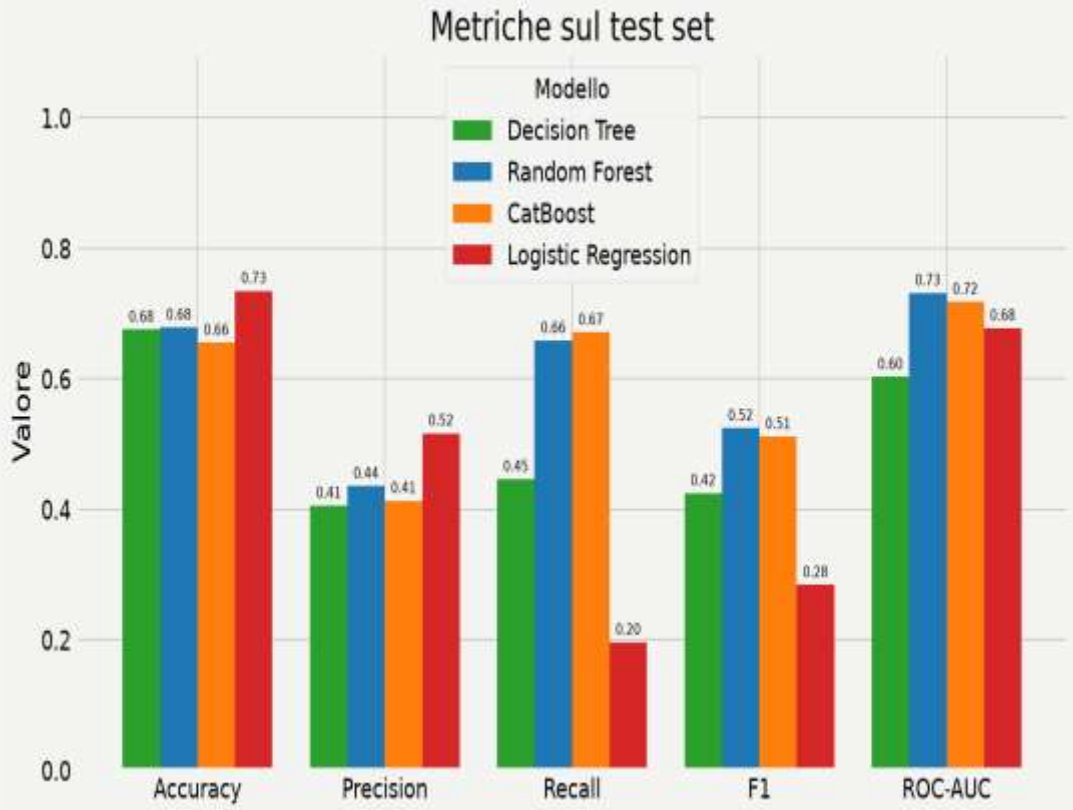


- Nell'albero lo stato relazionale vale il 63% delle decisioni: il modello si regge quasi su una variabile.
- Random forest e CatBoost distribuiscono il peso: lo stato relazionale scende a circa un quarto e salgono costo extra-studio, CGPA, età e semestre.
- Usano quindi informazioni che l'albero singolo trascura, coerentemente con il miglioramento che si vede nella slide successiva.

Importanza sommata sulle categorie di ogni variabile: riduzione media dell'impurità per albero e random forest, PredictionValuesChange per CatBoost. Stato civile (3% solo nella random forest) non mostrato.

Random forest e CatBoost incrementano l'AUC





La random forest offre il compromesso migliore

Passo	Modello	Soglia	Depressi trovati (su 240)	Studenti segnalati (su 893)	Precision	F1	AUC
1	Logistica (benchmark)	0,50	47 (20%)	91 (10%)	52%	0,28	0,677
2	Logistica	0,27	163 (68%)	447 (50%)	36%	0,47	0,677
3	Albero decisionale	0,41	190 (79%)	552 (62%)	34%	0,48	0,675
4	CatBoost	0,49	161 (67%)	390 (44%)	41%	0,51	0,718
5	**Random forest**	**0,48**	**170 (71%)**	**401 (45%)**	**42%**	**0,53**	**0,729**

- Con la stessa regola di soglia la logistica passa da 47 a 163 depressi trovati: gran parte del salto iniziale viene dalla soglia.
- L'albero trova più depressi di tutti, ma segnala il 62% degli studenti: ogni depresso in più rispetto alla random forest costa più di 7 segnalazioni.
- La random forest trova il 71% dei depressi segnalando il 45% degli studenti, con F1 e AUC più alti.